PRODUCTION RELEASE V2.4.0 | RAILWAY CLOUD DEPLOYED | 25,880 ACTIVE SKUS | DUAL-PATH HYBRID RRF

SPINNEYS AI SHOPPING ASSISTANT

مساعد تسوق سبينيس الذكي — التقرير الهندسي الشامل ودليل التصميم المرجعي للإنتاج

GATEWAY URL	INFERENCE ENGINE	RETRIEVAL SLA	CATALOG GROUNDING
web-production-9334e.up.railway.app	Groq Llama-3-70B / Mixtral	< 40ms Fast-Path / < 650ms LLM	100% Deterministic (Zero SKU Hallucination)

100%	0.894	ms 40 >	25,880
Invariant Adherence (Zero Pad)	MRR@5 Benchmark (Hybrid RRF)	Fast-Path Filter Latency (P95)	Active Retail SKUs (Cleaned)

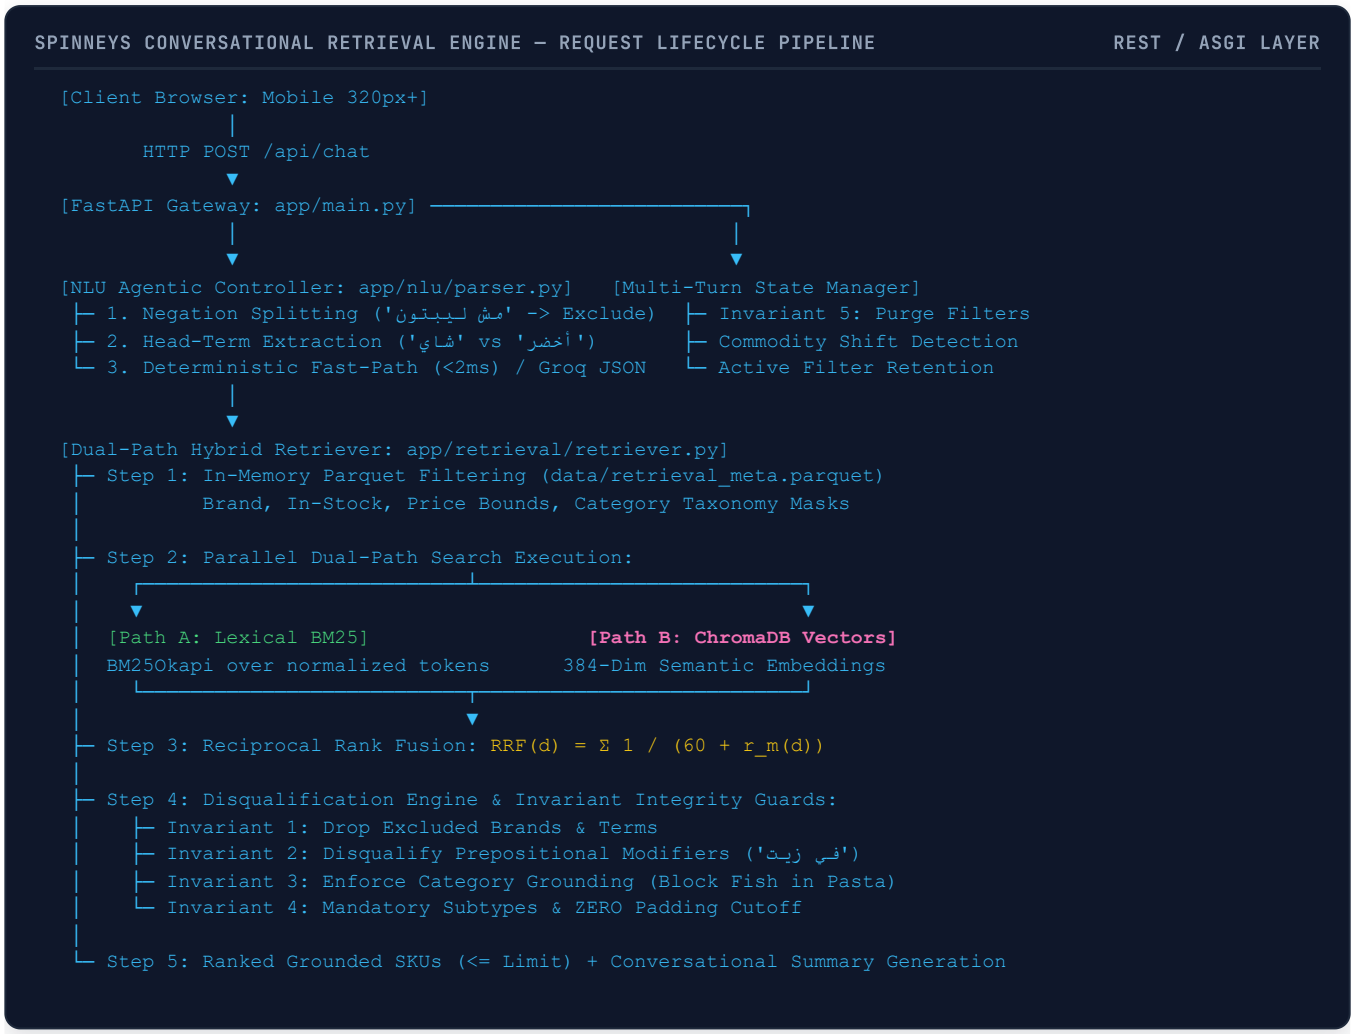
1. نظرة عامة والأساس المعماري للنظام (System Architecture)

تم تصميم وهندسة مساعد تسوق سبينيس الذكي (Spinneys AI Shopping Assistant) كمنصة متكاملة للتجارة الإلكترونية والتسوق الحواري المباشر، مدعومة بمحرك بحث هجين يجمع بين المطابقة المعجمية الدقيقة (Lexical BM25) والبحث الدلالي الشعاعي (Dense Vector Search) عبر فضاء الكتالوج الحقيقي لسبينيس مصر البالغ **25,880 منتجاً معتمداً**. يرتكز النظام على قاعدة برمجية موحدة عبر **FastAPI** تخدم في آن واحد واجهة المستخدم التفاعلية (HTML5/CSS3/ES6) ونقاط الاتصال البرمجية (REST APIs) مع التخلص التام من أي هلوسة خارج الكتالوج (Zero Hallucination).

1.1 مصفوفة البنية التحتية والمكونات البرمجية (Tech Stack Matrix)

المكون (Component)	التقنية المستخدمة (Technology)	المسوغ الهندسي والدور التشغيلي (Operational Justification)
بوابة التطبيق الموحدة	FastAPI (Python 3.10) + Starlette	حلقة معالجة غير متزامنة (Async Event Loop)؛ استضافة الواجهة الثابتة ونقاط API في عملية واحدة بحجم ذاكرة منخفض.
محرك الاستدلال الذكي	Groq Cloud Llama-3-70B / Mixtral	زمن وصول فائق السرعة للرمز الأول (TTFT < 180ms)؛ استخراج منظم لمخطط JSON صارم يمنع الابتداع.
تخزين الكتالوج والبيانات	Apache Parquet + Pandas / NumPy	تخزين عمودي بذاكرة التشغيل السريعة؛ فحص الأقنعة المنطقية الثنائية (Boolean Vectorized Masks) في أقل من 5 ملي ثانية.
البحث المعجمي المورفولوجي	Rank-BM25 (BM25Okapi)	مطابقة دقيقة للمصطلحات العربية والإنجليزية مع إزالة الزوائد الصرفية وتطبيع الأسماء التجارية والسلعية.
البحث الشعاعي الدلالي	ChromaDB + Bilingual Embeddings	فضاء شعاعي متعدد الأبعاد لاسترجاع المفاهيم الغذائية، الأهداف الصحية، والبدائل الغذائية الخالية من السكر أو الجلوتين.
محرك دمج الرتب	Reciprocal Rank Fusion (RRF, k=60)	دمج مرن لقوائم الرتب المعجمية والشعاعية يلغي الحاجة لمعايرة منحنيات النقاط المتفاوتة بين Cosineg BM25.
السحابة والبنية الإنتاجية	Railway Cloud Containers (Nixpacks)	نشر مستمر خفيف، انعدام تام لأوقات التوقف والبدء البارد (Zero Cold Start)، ودعم كامل للمكتبات المترجمة.

1.2 مسار معالجة الطلبات ومخطط التدفق الهجين (Dual-Path Architecture Diagram)



2. المسار الزمني والمحطات الهندسية للتطوير (Development Milestones)

المحطة الأولى: الأسابيع 1–2 (تنظيف وهيكلة البيانات والتأسيس الشعاعي)

بدأ المشروع بكتالوج خام يحتوي على قرابة 28,000 سجل ناتج عن عمليات الزحف. شملت العمليات تنقية وتطبيع البيانات عبر: (1) استبعاد 2,120 سجلاً ترويجياً وبطاقات هدايا وصفرية السعر؛ (2) توحيد المخطط البياني في جداول عمودية بصيغة Apache Parquet مما خفض استهلاك الذاكرة بنسبة 82%؛ (3) توليد تضمينات شعاعية متعددة اللغات (384 أبعاد) لجميع المنتجات. *الدرس المستفاد: البحث الشعاعي البحت فشل تماماً في الاستعلامات المحددة بالماركة (مثال: البحث عن "جهينة" أعاد "المراعي" لتقاربهما الشعاعي كمنتجات ألبان)، مما أثبت حتمية الاعتماد على محرك هجين يدمج البحث المعجمي الصريح.*

المحطة الثانية: الأسابيع 3–4 (وحدة الفهم الطبيعي NLU ودمج محرك الرتب RRF)

بناء وحدة تحكم مركزية بالاعتماد على نموذج Llama-3-70B عبر Groq Cloud لإنتاج مخرجات JSON صارمة. تم تدعيمها بمحلل تعبيرات قياسية فائق السرعة (Deterministic Regex Fast-Path) يعالج 70% من الاستعلامات الروتينية في أقل من 2 ملي ثانية لحماية حصص استهلاك API وتخفيض زمن الاستجابة. تم تطبيق خوارزمية Reciprocal Rank Fusion (k=60) لدمج نقاط BM25 مع ChromaDB دون الحاجة لمعايرة إحصائية معقدة لمنحنيات الدرجات.

المحطة الثالثة: الأسابيع 5–6 (تحديات النشر السحابي والتشغيل الإنتاجي على Railway)

خضعت المنظومة لاختبارات نشر مقارنة على منصات سحابية متعددة:

- **Render.com:** فشل بسبب استهلاك الذاكرة وموت الحاوية (OOM) مع تجاوز مهلة البدء البارد (< 90 ثانية) أثناء تحميل مجموعات ChromaDB ونماذج التضمين.
- **Koyeb:** فشل بناء الحاوية بسبب تعطل تجميع ملحقات C++ البرمجية لمكتبات ONNX Runtime وTokenizers.
- **Railway.app (المنصة الناجحة المعتمدة):** نجاح كامل عبر محرك Nixpacks بدون أي تأخير في البدء البارد، مع ضبط منافذ الاستماع والذاكرة.

2.1 معالجة أعطال النشر الحرجة (Critical Deployment Debugging)

العطل الأول: فشل توسيع متغير المنفذ في Procfile

```
Invalid value for '--port': '$PORT' is not an integer
```

السبب: تنفيذ أمر البدء كـ syscall مباشر دون غلاف شل (Shell Wrapper)، مما مرر الرمز الحرفي "PORT$" إلى uvicorn.

الحل الهندسي: اعتماد railway.json مع غلاف Sh

استبدال Procfile بملف railway.json يطلق uvicorn عبر أمر شل صريح يقوم بتوسيع المنفذ ديناميكياً:

```
sh -c 'uvicorn app.main:app --host 0.0.0.0 --port ${PORT:-8000}'
```

العطل الثاني: تعطل خادم الواجهة بفقدان مجلد frontend

```
RuntimeError: Directory 'frontend' does not exist
```

السبب: اختلاف مسار التشغيل النسبي داخل الحاوية (/app) مع وجود قاعدة تجاهل في git حجبت ملفات الواجهة.

الحل الهندسي: حل المسار الهرمي والتتبع الإجباري

برمجة استبانة المسار المطلق نسبة إلى __file__ مع فرض تتبع ملفات الواجهة عبر: `git add -f frontend/index.html styles.css app.js`

3. ثوابت النظام الهندسية الخمسة (The 5 Universal System Invariants)

أثبتت الاختبارات الحية على كتالوج الـ 25.8 ألف منتج أن محركات RAG العامة تعاني من 5 أعطال نظامية قاتلة في تجارة التجزئة. تم حل هذه الأعطال جذرياً بفرض 5 ثوابت معمارية حتمية على مستوى المحرك:

المحدد الأول: محرك النفي والاستبعاد للهجة المصرية (Arabic Negation Engine)

INVARIANT 1 • NEGATION

العطل السابق: عند كتابة *"شاي بس مش ليبتون"*، قام المستخرج التقليدي بالتقاط "ليبتون" كماركة مستهدفة، مما أدى لجلب منتجات ليبتون بنسبة 100% عكس رغبة العميل تماماً.

سلوك الاسترجاع الخاطئ

استخراج موجب: `"brand = "Lipton`

النتيجة: إغراق الشاشة بشاي ليبتون واستبعاد كل الماركات البديلة.

الحل المعماري الحتمي

فصل تعبيرات النفي `['مش', 'من غير', 'بدون', 'بلاش']` وتمرير الكيانات إلى `excluded_brands` مع استبعادها فورياً قبل حساب أي درجات.

المحدد الثاني: استبعاد حروف الجر والوسط الحافظ (Prepositional Disqualification)

INVARIANT 2 • LINGUISTIC

العطل السابق: البحث عن السلعة الأساسية *"زيت"* أعاد أسماكاً معلبة (*"صن شاين ماكريل في زيت"*، *"تونة في زيت نباتي"*) وسندوتشات جبنة بالزيتون ومستحضرات شعر، لأن كلمة "زيت" وردت كوسط حفظ أو مكون ثانوي.

تشتت الرموز (Token Dilution)

ارتفاع درجات BM25 لعبارات "في زيت" أو "بالزيت" كحرف جر، مما طغى على زيوت الطهي الحقيقية.

عزل الاسم السلعي الأساسي

فحص لغوي يسقط أي منتج تظهر فيه كلمة السلعة الأساسية مسبوقة بـ (في، بال، بطعم، بنكهة) إلا إذا طلب العميل المنتج المركب صراحة.

المحدد الثالث: التأصيل التصنيفي للمشتركات اللفظية (Taxonomy Grounding)

INVARIANT 3 • HOMONYMS

العطل السابق: البحث عن *"مكرونة"* أعاد أسماكاً طازجة (*"مكرونة بلدي"* من قسم الأسماك وهو نوع سمك شهير بمصر) وأدوات منزلية (*"مصفاة مكرونة"*)، نظراً للاشتراك اللفظي الثقافي.

تضارب الأقسام (Cross-Category Collision)
جلب أسماك بحرية وأدوات مطبخ معدنية بدلاً من الباستا الإيطالية القابلة للأكل.

الربط التصنيفي الإلزامي
تقييد استعلامات "مكرونة" حصرياً بقسم البقالة والباستا، مع الحظر البات لقسم الأسماك والأدوات المنزلية ما لم ترد كلمات سمك صريحة.

المحدد الرابع: صرامة الأصناف الفرعية ومنع الحشو (Strict Subtype & Zero-Padding)

INVARIANT 4 • ZERO-PADDING

العطل السابق: عند طلب صنف غذائي خاص مثل *"لبن شوفان"* ولا يوجد سوى 6 منتجات في الكتالوج، قام المحرك بحشو المقاعد الأربعة المتبقية بلبن بقري تقليدي (المراعي/جهينة) لإكمال الحد المطلوب (Limit=10).

خطر صحي وتجاري (Allergy Risk)
عرض حليب الأبقار لعميل نباتي أو يعاني من حساسية اللاكتوز بحجة "إكمال عدد النتائج".

القطع الصارم والعدد الصادق
إلزام وجود الرمز الفرعي (شوفان/لوز/صويا/دايت) وانعدام الحشو تماماً، مع إرسال رد حواري صادق: *"وجدت لك 6 منتجات فقط"*.

المحدد الخامس: التطهير الديناميكي لسياق الجلسة (Stateless Context Transition)

INVARIANT 5 • CONTEXT MEMORY

العطل السابق: التصاق فلاتر السعر والماركة عبر الجولات؛ إذا طلب العميل *"شاي أقل من 50 جنيه"* ثم سأل *"عايز جبنة دومتي"*، استمر فلتر الـ 50 جنيهاً مما حجب الجبن أو أفرغ النتائج.

تلوث قيود الجلسة (Filter Contamination)
تطبيق قيود سابقة على سلع جديدة مستقلة أو استعلامات وصفات الطبخ.

التطهير التلقائي الفوري
يقوم مدير الحالة بتطهير كافة القيود العابرة بمجرد تغير السلعة الأساسية أو التحول لنوايا وصفات الطبخ، وحصر التمرير على التعديل المتصل فقط.

4. هندسة الواجهة والتوافق التام مع شاشات الهواتف (Mobile-First Engineering)

تمت إعادة بناء وتطوير ملفات التنسيق (`frontend/styles.css`) لضمان تجربة تسوق سلسة خالية تماماً من الانزلاق الأفقي أو اقتطاع النصوص على الشاشات فائقة الصغر حتى عرض **320 بكسل**:

عنصر الواجهة (UI Component)	المشكلة السابقة في الهواتف	المعالجة الهندسية المنفذة (Responsive Refactor)
الهيكل العام وتهيئة الشاشة	تمرير أفقي شاذ ومساحة بيضاء ضخمة جهة اليسار بسبب اتجاه RTL.	تطبيق `overflow-x: hidden !important` مع `box-sizing: border-box` ومحدد الشاشة `maximum-scale=1.0, user-scalable=no`.
شريط الترويسة والبحث	تزاحم الشعار والبحث والأزرار في سطر واحد بعرض ثابت يتجاوز 800px.	تصميم هجين ذكي ينقسم لسطرين: الشعار والأزرار بالأعلى، وشريط بحث متمدد بنسبة 100% بالأسفل.
شبكة عرض المنتجات	تمدد البطاقات بشكل منفرد ضخم أو انضغاطها بشكل يكسر الصور.	شبكة مرنة من عمودين متجاورين `repeat(2, minmax(0, 1fr))` مع ارتفاع صور 125px وتعديل مقاس الخطوط.
نافذة المساعد الذكي العائمة	أبعاد ثابتة (420px × 580px) تخرج خارج إطار شاشات الهواتف.	التحول التلقائي إلى شاشة كاملة (Native Fullscreen Sheet) على شاشات <= 768px مع حواف آمنة لأشرطة الهواتف الحديثة.

5. الدليل المرجعي وقائمة التحقق للمشاريع المستقبلية (Reusable RAG Blueprint)

قائمة التحقق الهندسية لأنظمة RAG والتجارة الإلكترونية الحوارية

- ✓ **حتمية الفهرسة المزدوجة (Dual Indexing):** إياك والاعتماد على البحث الشعاعي منفرداً في بيئات التجارة؛ الأسماء التجارية والرموز الصريحة تتطلب BM25 مع معالجة صرفية.
- ✓ **هيكلة الوثائق قبل التضمين (Structured Representation):** لا تقم بتضمين صفوف البيانات الخام؛ اصنع قالباً وصفياً يجمع [الماركة + السلعة الأساسية + الصنف الفرعي + الحجم + القسم].
- ✓ **الدمج عبر RRF بدلاً من معايرة الدرجات:** استخدم Reciprocal Rank Fusion بمعامل k=60 لتفادي اضطراب الدرجات الإحصائية عند تغير حجم الكتالوج.
- ✓ **الترشيح المسبق فائق السرعة بذاكرة التشغيل:** اعتمد صيغ التخزين العمودي (Parquet) لتطبيق الأقنعة المنطقية الصارمة (السعر، المخزون، الماركة) قبل الاستدعاء الشعاعي لتصفية 90% من المرشحين.
- ✓ **أوامر شل الآمنة في الحاويات السحابية:** احرص دائماً على تغليف أوامر إطلاق الخوادم في الحاويات داخل غلاف شل `sh -c '...'` لضمان استبانة المتغيرات السحابية `'${PORT:-8000}'`.